

Errata: Unicode文字境界を保つチャンク化の採用

v1.0.1 追補。2026年6月4日。

要点

v1.0.0 の広域的な意味地図を差し替えるものではない。ただし旧方式では、トークン列を一定の長さで切ってから文字列に戻していたため、一部のチャンクで文字の途中が切れ、置換文字 U+FFFD が本文に入ることがあった。本補遺では、同じ 700 トークン幅・100 トークン重なりを保ちつつ、文字の途中で切らないように境界を調整する改訂方式を検証した。

U+FFFD が発生する理由は、tiktoken のトークンが Unicode 文字そのものではなく、UTF-8 バイト列を分割した単位であるためである。漢字などの1文字は複数バイトで表され、場合によっては複数トークンにまたがる。固定長のトークン断片だけを復号すると、断片の先頭または末尾が不完全な UTF-8 バイト列になり、復号時に置換文字 U+FFFD として現れることがある。

本コーパスでは、700 トークンに達した改訂方式チャンク 265 件の文字数中央値は 458 字であり、p10-p90 は 432-489 字であった。したがって、本稿の 700 トークン窓は、漢字を中心とする本文でおおむね 460 字前後に相当する。ここでの文字数は Python 文字列上の文字数であり、句読点や記号も含む。

100 トークン重なりにより、境界付近の本文は隣接チャンクにも部分的に含まれる。そのため、境界差の影響は本文重心や巻単位の集計では平均化されやすく、今回の大局的安定性を支える要因の一つと考えられる。ただし、この重なりはチャンク単位の1位参照源判定の揺れを完全に抑えるものではない。

技術注: 実装では tiktoken の offsets を用いてトークン位置を Python 文字列の文字位置へ対応させた。旧方式の再現確認では、v1.0.0 と同じ固定長トークン列の復号を用いた。

文字列品質

方式	チャンク数	置換文字を含むチャンク	置換文字数	トークン数中央値	トークン数平均
旧方式	433	256	326	700	692.935
改訂方式	433	0	0	700	692.679

数値評価

埋め込みモデルは text-embedding-3-large。旧方式の埋め込みは既存の埋め込みキャッシュを用い、改訂方式の本文断片だけを同じモデルで新規に埋め込んだ。公開成果物には、生本文やチャンク本文そのものは含めない。

比較対象	件数	最小	p10	中央値	平均	p90	最大
同一位置チャンク	433	0.89001	0.966485	0.997813	0.98916	1	1
本文ごとの重心	15	0.995906	0.996709	0.998511	0.99809	0.998773	0.999538
宗派ごとの重心	11	0.997908	0.997908	0.998751	0.998713	0.999069	0.999086

同じ本文ごとに旧方式と改訂方式の重心を比較すると、最小値でも 0.995906 であり、全体として高い一致を示した。

本文	ID	旧方式/改訂方式の重心類似度
佛説阿彌陀經	t0366_amida_sutra	0.995906
大樂金剛不空眞實三摩耶經	t0243_rishu_kyo	0.996541
般若波羅蜜多心經	t0251_heart_sutra	0.996961
觀世音菩薩普門品	t0262_kannon_chapter	0.997215
妙法蓮華經	t0262_lotus_sutra	0.997908
稱讚淨土佛攝受經	t0367_praise_pure_land	0.998081
佛說觀無量壽佛經	t0365_meditation_sutra	0.998349

本文	ID	旧方式/改訂方式の重心類似度
佛説無量壽經	t0360_larger_sukhavati	0.998511
金剛般若波羅蜜經	t0235_diamond_sutra	0.998672
大毘盧遮那成佛神變加持經	t0848_maha_vairocana	0.998693
大方廣佛華嚴經	t0279_flower_garland	0.998707
維摩詰所説經	t0475_vimalakirti	0.998728
解深密經	t0676_samdhinirmocana	0.998751
金剛頂一切如來眞實攝大乘現證大教王經	t0865_vajrasekhara	0.998787
顯淨土眞實教行證文類	kyogyoshinsho	0.999538

三層別の確認

ここでいう意味層は、ターゲットチャンクと参照源チャンクの埋め込み cosine に基づく参照源混合である。したがって、意味層の入れ替わりは埋め込み空間全体の崩れではなく、埋め込みを用いた局所的な参照源順位が境界処理差に反応したものとして読む。

三層参照源混合地図についても、旧方式と改訂方式を同じ条件で比較した。意味層の参照源混合では、チャンク単位の支配的参照源が 33 / 197 で入れ替わった。一方、巻別の支配的参照源は変化せず、文体・語彙層の入れ替わりは 1 / 197、典拠マーカ層は 0 / 197 であった。

層	チャンク	重みcos中央値	L1平均	支配参照源の変化	巻別支配参照源の変化
意味層（参照源混合）	197	0.992013	0.123899	33 / 197	0 / 7
文体・語彙層	197	1	0.000657	1 / 197	0 / 7
典拠マーカ層	197	1	0	0 / 197	0 / 7

典拠マーカ層では、マーカ検出チャンク数と総マーカ検出数も一致した。

指標	旧方式	改訂方式
マーカ検出チャンク	99	99
総マーカ検出数	170	170
検出ベクトル完全一致率	1	
検出ベクトルが変化したチャンク	0	




図: 旧方式と改訂方式の本文重心。線は同じ本文の対応を示す。

解釈

旧方式で発生した U+FFFD は、本文品質と再現性の問題として明確に避けるべきである。一方、同じ位置にあるチャンク同士の埋め込み類似度は平均 0.98916、中央値 0.997813 であり、本文ごとの重心と宗派ごとの重心も高い一致を示した。したがって、v1.0.0 の大局的な意味地図をただちに否定するものではない。

ただし、意味層の参照源混合は、チャンク単位の1位参照源判定において Unicode 境界処理の差に一定の感度を示した。これは、参照源候補同士が近い局所箇所では入力ノイズにより順位が入れ替わり得ることを示す。一方で、100 トークン重なりは境界付近の差異を隣接チャンクへ部分的に分散させ、本文重心や巻単位の傾向を安定させる方向に働いたと考えられる。巻別の支配的参照源、文体・語彙層、典拠マーカー層は大きく崩れなかった。三層に分けることにより、どの層が揺れ、どの層が安定しているかを分離して確認できた点も、本稿の方法上の利点である。

本文断片の表示、SAT 行範囲との対応、個別チャンク近傍、引用候補の精査では、旧方式を基準にしない。今後は、文字境界を保つ改訂方式を基準処理とする。