

意味埋め込みによる仏教文献の探索地図：宗派別参照群・異訳比較・多言語対応の予備的分析

上山大信

2026 年 6 月 2 日

要旨

本稿は、漢訳仏典および日本撰述仏教文献を対象に、意味埋め込みを用いて仏教文献群を探索するための意味地図を構築する予備的研究である。対象には、浄土系、法華系、真言系、禅系、華嚴系、法相系に関係する 15 テキスト、433 チャンクを用いた。各本文を `text-embedding-3-large` で埋め込み、本文単位のベクトルはチャンクベクトルの平均として得た。さらに、宗派別参照群重心と訳者重心を計算し、平均点の 2 次元配置、チャンク分布、類似度ヒートマップ、近傍テキストを確認した。加えて、漢訳『解深密経』と 84000 英訳 *The Teaching Explaining the Thought* (Toh 106) を用い、言語を越えて同一經典性が近傍関係として現れるかを小規模に検証した。

結果として、阿弥陀経とその玄奘訳別訳である『稱讃浄土佛攝受經』は、意味埋め込みでは高い類似度を示し、文字単位 TF-IDF では低い類似度を示した。この対照は、意味埋め込みが内容・主題の近さを主に捉え、訳語選択や表記上の差は別の特徴量として扱う必要があることを示唆する。チャンク分布では、本文平均点だけでは見えにくい各經典内部の広がりや重なりが確認でき、とくに阿弥陀経二訳は比較対象ペアのなかで一貫して高いチャンク近傍混合率を示した。親鸞文献側の小実験では、『入出二門偈』に玄奘訳『称讃浄土経』の明示的参照が確認され、『教行信証』では阿弥陀経二訳のどちらか一方だけに還元しにくい重層的な近さが見られた。浄土三部経や真言系密教經典には、投入した参照テキスト群の範囲で一定の主題的まとまりが見られたが、禅系については經典のみでは宗派的伝統の差を十分に表現できなかった。多言語パイロットでは、Toh 106 英訳の最近傍が漢訳『解深密経』となった。ただし、これは英訳 1 本による最小実験であり、同一經典判定の性能評価には対応ペアの拡張が必要である。

キーワード: 漢訳仏典、宗派比較、意味埋め込み、阿弥陀経、玄奘、鳩摩羅什、多言語比較、仏教文献情報学

1 はじめに

日本仏教の各宗派は、それぞれ特定の經典、祖師文献、儀礼的読誦テキストを重視してきた。たとえば浄土系では浄土三部経および祖師文献が重要であり、真言宗では大日経、金剛頂経、理趣経などの密教經典が中心的な位置を占める。一方、禅宗では般若心経、金剛経、維摩経などが参照されるが、宗派の特徴は經典そのものよりも語録、清規、祖師文献に強く現れる可能性がある。

近年の大規模言語モデルおよび埋め込みモデルは、テキストの意味的近さを高次元ベクトルとして表現できる。本研究では、この手法を仏教文献に適用し、宗派ごとの参照テキスト群の配置を可視化できるかを検討する。あわせて、阿弥陀経の異訳や同一訳者の複数テキストを用い、意味的近さと翻訳文体の差がどのように現れるかを予備的に確認する。さらに、漢訳仏典と 84000 Reading Room で公開されている英訳を対照し、意味埋め込みが言語を越えた同一經典性をどの程度拾えるかを試験的に確認する。

本稿は、仏教文献情報学、漢訳仏典の異訳研究、stylometry による著者・訳者判定、多言語・多訳文献のラインメント研究と接続しうる。特に、文字特徴に基づく文体計量は Burrows の Delta 以降の著者判定研究で蓄積があり [14, 15]、漢訳仏典についても訳語・語彙対応を丁寧に扱う研究資源が存在する [16]。ただし現段階では、特定の訳者判定モデルや宗派分類器を提示するものではない。中心命題は、意味埋め込みは内容・主題的近接を探索するには有効だが、宗派的伝統、訳者差、引用経路を精密に判定するには、文体特徴量および引用・参照情報を別レイヤーとして導入する必要がある、という点にある。

本稿の目的は、宗派分類の正解モデルを作ることではない。むしろ、各宗派が参照するテキスト群を意味空間上に置いたとき、どのような近接関係や解釈上の問題が現れるかを把握することである。

2 研究課題

本稿では、以下の四つの問いを設定する。

- 1. 意味埋め込みによって、浄土三部経や真言系密教経典のような主題的まとまりを確認できるか。
- 2. 宗派ごとの参照テキスト群を重心として可視化した場合、投入テキスト群の主題的近接をどの程度表現できるか。
- 3. 阿弥陀経の異訳および同一訳者の複数テキストを比較したとき、意味の近さと翻訳文体の差を区別できるか。
- 4. 漢訳仏典と 84000 英訳を比較したとき、同一経典性は言語差を越えて近傍関係として現れるか。

3 データ

本文は主に SAT 大正新脩大藏経テキストデータベースから取得した。『顯浄土眞實教行證文類』については、浄土真宗本願寺派総合研究所『浄土真宗聖典』聖教データベースの収載・利用規定を確認し、同データベースを利用した旨を明記する必要があるため、本稿の参考文献にも同データベースを掲げる。一部の検証用テキストには、全文ではない既存取得本文を用いた。本稿で用いたテキスト数は 15、チャンク数は 433 である。多言語パイロットでは、SAT 由来の漢訳『解深密経』と、84000 Reading Room で公開されている *The Teaching Explaining the Thought* (Toh 106) 英訳を用いた。84000 本文は研究用キャッシュとして扱い、本文そのものは本稿に転載しない。原本文の再配布を避けるため、公開する場合は取得手順、前処理スクリプト、チャンク ID、類似度行列、図生成コードなどの派生情報を中心とする。

親鸞文献における阿弥陀経二訳の参照分析では、上記コーパスとは別に、真宗聖典検索サイト所収の『入出二門偈』該当頁も参照した。この追加資料は宗派別マップ全体の平均ベクトルには組み込まず、経名・訳者名の明示、訳語・句の指標、ならびに『教行信証』チャンクと阿弥陀経二訳チャンクの近傍関係を確認するために用いた。

表 1: 対象テキストとコーパス情報

使用ラベル	テキスト	ID・出典	全文性	字数/チャンク	備考
浄土系	佛説無量壽經	T0360/SAT	v0 取得範囲	10307/27	康僧鎧訳。浄土三部経の大経。
浄土系	佛説觀無量壽佛經	T0365/SAT	v0 取得範囲	9003/23	曇良耶舎訳。浄土三部経の觀経。
浄土系	佛説阿彌陀經	T0366/SAT	v0 取得範囲	2368/7	鳩摩羅什訳。浄土三部経の小経。
浄土系	稱讃浄土佛攝受經	T0367/SAT	v0 取得範囲	4630/12	玄奘訳。阿弥陀経系の異訳比較レイヤー。
浄土真宗	顯浄土眞實教行證文類	聖教 DB	既存取得本文	78978/197	親鸞撰述。J-SOKEN 聖教 DB を出典確認先とする。
法華系	妙法蓮華經	T0262/既存取得	抜粋	4718/13	鳩摩羅什訳。序品第一相当の既存取得抜粋で、法華系評価は暫定。
法華・禅系	觀世音菩薩普門品	T0262/SAT 範囲	品単位	2134/6	鳩摩羅什訳。觀音経として読まれる第二十五品。

使用ラベル	テキスト	ID・出典	全文性	字数/チャンク	備考
真言系	大毘盧遮那成佛神變加持經	T0848/SAT	v0 取得範囲	10770/28	善無畏・一行訳。大日経。
真言系	金剛頂一切如来眞實攝大乘現證大教王經	T0865/SAT	v0 取得範囲	8342/22	不空訳。金剛頂経系の代表として扱う。
真言系	大樂金剛不空眞實三摩耶經	T0243/SAT	v0 取得範囲	3309/9	不空訳。理趣経。
禪・真言系	般若波羅蜜多心經	T0251/SAT	v0 取得範囲	1307/3	玄奘訳。勤行レイヤーとして扱う。
法相系	解深密經	T0676/SAT	v0 取得範囲	7082/18	玄奘訳。多言語パイロットの対応漢訳。
禪系	金剛般若波羅蜜經	T0235/SAT	v0 取得範囲	5909/15	鳩摩羅什訳。禪系参照テキスト候補。
禪系	維摩詰所説經	T0475/SAT	v0 取得範囲	12129/32	鳩摩羅什訳。禪系参照テキスト候補。
華嚴系	大方廣佛華嚴經	T0279/SAT	v0 取得範囲	7743/21	實叉難陀訳。八十華嚴。

注: 「v0 取得範囲」は本実験用キャッシュで処理した範囲を示し、校訂上の全文性を保証しない。訳者名は SAT および大正蔵目録系の表記を確認し、T0365 は晁良耶舎、T0279 は實叉難陀とした。

本実験は予備的なものであり、すべての大部経典を完全な全文として取得できているわけではない。表中の「v0 取得範囲」は、SAT または既存取得ファイルから本実験で処理できた範囲を意味し、必ずしも校訂上の完全本文を保証しない。特に法華経の既存取得本文は短く、全文ではない可能性が高い。また、SAT 本文の再配布ではなく、実験結果の要約と派生データの確認を目的とする。取得日は、ローカルキャッシュ上では 2026 年 6 月 1 日から 2 日の作業時点である。

4 方法

4.1 チャンク化と埋め込み

SAT 由来本文は HTML から本文行を抽出し、表示用ボタン、画像参照、余分な空白を除いたうえで行本文を連結した。既存取得本文および聖教 DB 由来本文については、非空行を連結し、空白を除去した。句読点・異体字・校訂記号の厳密な正規化はまだ行っていない。したがって、今回の処理は意味埋め込み用の最小前処理であり、文体分析用の正規化とは別に設計し直す必要がある。

本文は tiktoken の cl100k.base でトークン化し、既定で 700 トークン、100 トークンの重なりによりチャンク化した。巻・品・段落などの自然境界は v0 では考慮していない。各チャンクに対して text-embedding-3-large による埋め込みを作成した。同一モデル・同一本文のチャンクについてはキャッシュを利用し、再実行時に API を呼び直さないようにした。

本文単位のベクトルは、当該本文に属するチャンクベクトルの単純平均として計算した。平均前のチャンクベクトル、および平均後の本文ベクトルに対して、明示的な L2 正規化は行っていない。類似度計算時にはコサイン類似度を用いるため、比較時にベクトル長の影響は正規化される。

4.2 類似度と重心

本文間の類似度はコサイン類似度によって計算した。宗派別参照群重心は、当該宗派に属する core_sutra および founder_text の本文ベクトルの平均として定義した。ここで core_sutra は中心経典、founder_text は祖師文献を表す作業用ラベルである。訳者重心は、同一訳者に属する複数テキストの本文ベクトルの平均として定義した。ただし、今回の訳者重心はサンプル数が少ないため、可視化上の補助線として扱う。

4.3 可視化と対照実験

本文ベクトル、宗派別参照群重心、訳者重心を同一空間に配置し、2次元表示にはPCAを用いた。PCAの乱数シードは`random.state=0`とした。本文平均点マップにおける第1軸・第2軸の寄与率は、それぞれ23.3%、18.7%であり、2軸合計で42.0%である。阿弥陀経二訳については、意味埋め込みに加えて文字単位TF-IDFも計算した。文字単位TF-IDFでは2から5文字のn-gramを用いた。これは、意味的近さではなく、語彙選択や表記の差を捉えるための簡易的な対照実験である。

平均ベクトルだけでは、長い経典や複数主題を含む文献の内部的な広がりが見えなくなる。そこで、主要テキストについてはチャンク単位の埋め込みをPCAで2次元表示し、各テキストのチャンク群に対して1標準偏差楕円を重ねた。主要チャンク分布図における第1軸・第2軸の寄与率は、それぞれ6.9%、4.4%であり、2軸合計で11.4%である。

また、2次元投影の重なりは歪みを含むため、元の高次元埋め込み空間で、あるテキストのチャンクのtop-k近傍に相手テキストのチャンクがどの程度入るかを「チャンク近傍混合率」として計算した。二つのテキストA、Bのチャンク集合を $C = A \cup B$ とし、各チャンク $c \in C$ について、同一チャンク自身を除いたtop-k近傍 $N_k(c)$ を求める。 $N_k(c)$ のうち、 c と異なるテキストに属するチャンクの割合を $r(c)$ とし、混合率を $M(A, B) = \text{mean}_{c \in C} r(c)$ と定義した。本文中では特に断らない限り $k = 5$ を用いる。

4.4 多言語パイロット

多言語比較では、84000 Reading Roomの*The Teaching Explaining the Thought* (Toh 106)をHTMLから抽出し、SAT由来の漢訳『解深密経』(T0676)と比較した。対照群として、金剛経、維摩経、般若心経、阿弥陀経の漢訳を加えた。評価は、84000英訳の本文ベクトルから見た漢訳テキストの最近傍順位によって行った。

5 結果

5.1 宗派別参照テキスト群の意味配置

図1に、本文ベクトルおよび訳者重心をPCAで2次元表示した結果を示す。浄土系参照テキストは左上方向に比較的近く配置され、真言系密教経典は下方向にまとまる傾向が見られる。一方、禅系の経典のみからは、曹洞宗・臨済宗・黄檗宗の伝統差は明確には出なかった。これは宗派差が存在しないという意味ではなく、今回投入した経典層だけでは宗派的伝統を表す特徴が不足していることを示す。




図 1: 意味埋め込みによる宗派別参照テキスト群の意味配置。丸は本文、菱形は訳者重心を表す。PCA 第 1 軸・第 2 軸の寄与率は図中の軸ラベルに示した。

5.2 チャンク分布と広がり

図 2 は、本文平均点ではなく、各本文を構成するチャンク群を点として表示したものである。楕円は各テキストの 1 標準偏差範囲を表す。平均点マップでは一点に集約されるテキストも、チャンク単位では主題の広がりや他テキストとの部分的重なりを持つことが分かる。特に、教行信証は引用や教義的総合を含むため、チャンク分布の広がり大きい。




図 2: 主要テキストのチャンク分布と 1 標準偏差楕円。小点はチャンク、濃い丸は各テキストのチャンク重心を表す。2 次元 PCA の寄与率は低いため、重なるの解釈には高次元空間の混合率を併用する。

図 3 は、代表的な組み合わせを局所的に PCA 表示したものである。阿彌陀経二訳では、平均点だけでなくチャンク分布にも重なりが見られる。一方、真言系密教經典や般若・法相・禪系対照では、平均点の近さと分布の形が一致しない場合があり、本文全体を一点に潰すことの情報損失が確認できる。




図 3: 代表ペア・グループのチャンク分布。各パネル内で PCA を再計算し、局所的な重なりを見やすくしている。

高次元空間で計算したチャンク近傍混合率を図 4 に示す。値が大きいほど、相手テキストのチャンクが近傍に混ざりやすい。阿彌陀経二訳は 0.37 と高く、異訳間で分布が混ざる傾向が確認できる。対照的に、阿彌陀経と理趣経のような主題差の大きい組み合わせでは混合率が低い。




図 4: チャンク近傍混合率による分布重なり。各セルは、二つのテキストのチャンクを合わせたとき、各チャンクの top-5 近傍に相手テキストのチャンクが入る割合の平均を表す。

図 5 は、本文平均ベクトルの類似度とチャンク近傍混合率を同時に見たものである。右上に位置する阿弥陀經二訳は、平均点も近く、チャンク分布も強く混ざっている。一方、教行信証と浄土三部經は本文平均ベクトルでは近いが、チャンク近傍混合率は低めである。これは、教行信証が三部經を根拠として強く参照しつつも、本文全体としては引用、注釈、教義的論述を含む大きな複合文献であり、全チャンクが三部經チャンクと一様に混ざるわけではないことを示す。




図 5: 本文平均ベクトルの類似度とチャンク近傍混合率の関係。右上ほど、本文平均点も近く、部分単位でも分布が混ざりやすい。

表 2 に、阿弥陀経二訳のチャンク近傍混合率を top-k 別に示す。k を 1、3、5、10 に変えても、阿弥陀経二訳は今回比較した 55 ペアのなかで最大の混合率を示した。ただし、ラベルランダム化による完全混合参照分布の平均は観測値より高い。これは、この混合率が「完全にラベルがランダムに混ざるほど大きくなる」指標であり、通常の有意差検定として単純に読むべきではないことを意味する。したがって本稿では、このラベルランダム化を通常の有意差検定ではなく、ラベルが意味構造と独立に割り当てられた場合の完全混合参照として用い、主要な解釈は実テキストペア間の相対順位と top-k 感度に基づける。

表 2: 阿弥陀経二訳におけるチャンク近傍混合率の top-k 感度

top-k	観測混合率	55 ペア中順位	完全混合参照平均	完全混合参照分布の 95% 範囲
1	0.1579	1	0.4897	0.2105–0.7368
3	0.2632	1	0.4911	0.3333–0.6140
5	0.3684	1	0.4911	0.3787–0.5789
10	0.4474	1	0.4908	0.4263–0.5421

表 3 に、代表的な組み合わせについて、最も近いチャンクペアを示す。本文の転載を避けるため、チャンク ID と類似度のみを示した。教行信証と三部経の組み合わせでは、橋渡しチャンクの類似度は 0.71 から 0.80 程度と高い。したがって、三部経との部分的対応は確かに現れているが、混合率は低く、教行信証全体が三部経そのものと同じ分布になるわけではない。

表 3: 代表ペアの橋渡しチャンク。KGS は教行信証を表す。

ペア	最近接チャンクペア	チャンク類似度	本文類似度	混合率
阿弥陀/稱讃	T0366 0005 / T0367 0010	0.7672	0.8825	0.3684
教行/無量寿	KGS 0002 / T0360 0004	0.7969	0.8797	0.0438
教行/観無量寿	KGS 0088 / T0365 0002	0.7095	0.8375	0.0127
教行/阿弥陀	KGS 0098 / T0366 0005	0.7250	0.8058	0.0147
無量寿/観無量寿	T0360 0021 / T0365 0008	0.7660	0.9102	0.1680
金剛頂/理趣	T0865 0000 / T0243 0000	0.8176	0.8405	0.1161
金剛/維摩	T0235 0004 / T0475 0022	0.7235	0.8770	0.1404
阿弥陀/理趣	T0366 0005 / T0243 0007	0.5900	0.6816	0.0375

主要テキスト間の類似度を図 6 に示す。阿弥陀経、玄奘訳別記、無量寿経、観無量寿経の近接が確認できる。また、大日経、金剛頂経、理趣経の間にも比較的高い類似度が見られる。




図 6: 主要テキスト間のコサイン類似度。値が大きいほど意味埋め込み上で近い。

5.3 阿弥陀経二訳

鳩摩羅什訳『佛説阿彌陀經』と玄奘訳『稱讃浄土佛攝受經』を比較したところ、意味埋め込みでは高い類似度を示した。一方、文字単位 TF-IDF では低い類似度となった（図 7）。




図 7: 阿弥陀経二訳の類似度比較。意味埋め込みは内容の近さを、文字単位 TF-IDF は語彙・表記差を強く反映する。右側の「チャンク最良一致平均」はチャンク平均ベクトル類似度とは別指標である。

図 7 の「全文直接埋め込み」値 0.8943 は、阿弥陀経二訳をそれぞれ一つの入力として直接埋め込んだ先行小実験の値である。一方、表 4 のチャンク平均ベクトル類似度 0.8825 は、本稿の宗派別参照群コーパスで用いたチャンク平均方式による値である。両者は前処理単位が異なるため完全には一致しないが、いずれも意味的近接が高いことを示している。

表 4: 阿弥陀経二訳に関する指標の整理

指標	値	説明
全文直接埋め込み類似度	0.8943	二訳それぞれを全文単位で直接埋め込んだ小実験の値。
チャンク平均ベクトル類似度	0.8825	本稿の主分析で用いる、各チャンク埋め込み平均ベクトル同士の値。
チャンク最良一致平均	0.7108	二訳間のチャンク対応に基づく平均的な近さ。
文字単位 TF-IDF 全文	0.1928	文字 n-gram による語彙・表記類似度。
文字単位 TF-IDF チャンク最良一致平均	0.1424	チャンク単位の文字特徴による近さ。

表 5: 阿弥陀経から見た近傍テキスト

近傍テキスト	コサイン類似度
稱讃浄土佛攝受經	0.8825
無量寿經	0.8694
觀無量寿經	0.8446
妙法蓮華經拔粹本文	0.8275
教行信証	0.8058

5.4 親鸞文献における阿弥陀経二訳

親鸞が阿弥陀経をどの漢訳、あるいはどの注釈伝統を通して読んでいたかは、意味埋め込みだけで判定できる問題ではない。鳩摩羅什訳『佛説阿彌陀經』と玄奘訳『稱讃浄土佛攝受經』は原内容が近く、意味ベクトルでは

強く近接する。そのため、本稿では追加の小実験として、証拠を三層に分けた。第一に、経名・訳者名の明示である。第二に、羅什訳または玄奘訳に寄りやすい訳語・句の指標である。第三に、『教行信証』チャンクが阿弥陀経二訳のどちらのチャンクへ近いかという意味近傍である。

図 8 に、親鸞文献側のソース指標を示す。『入出二門偈』該当頁では、『称讃浄土経』と玄奘訳であることが明示され、玄奘訳側の讃嘆モチーフに対応する語句も検出された。一方、『教行信証』では、羅什訳側に寄る句と『称讃浄土経』の経名参照が併存する。したがって、『教行信証』については、単純に羅什訳または玄奘訳のどちらか一方に帰属させるより、三部経、異訳、法照・善導・元照などの注釈伝統が重なる文献として読む必要がある。




図 8: 親鸞文献側の阿弥陀経二訳ソース指標。宗派別参照群マップとは別の引用・参照ソース小実験であり、経名・訳者名の明示と、訳語・句の指標を分けて表示した。

『教行信証』本文平均ベクトルから見た類似度は、羅什訳『阿弥陀経』が 0.8058、玄奘訳『稱讃浄土佛攝受経』が 0.8152 であった。玄奘訳の方がわずかに高いが、差は 0.0094 にすぎない。図 9 のチャンク単位の推移を見ても、二訳への近さは本文全体で交錯している。これは、親鸞文献の内部に、经文引用、釈義、祖師文献引用、教義的論述が混在していることを反映していると考えられる。




図 9: 『教行信証』チャンクから見た阿弥陀経二訳への最大類似度。宗派別参照群マップとは別の引用・参照ソース小実験であり、赤は玄奘訳、青は羅什訳への近さを表す。

表 6: 親鸞文献側から見た阿弥陀経二訳の証拠

対象	羅什訳側	玄奘訳側	解釈
教行信証	固有句あり、チャンク最大 0.7250	経名参照あり、本文平均 0.8152	両訳・注釈伝統が重なる。単独決定は不可。
入出二門偈 p543	目立たず	称讃浄土経・玄奘訳を明示	玄奘訳参照の強い証拠。
阿弥陀経集註	未投入	未投入	次段階の本命資料。経文・註記・裏書の分離が必要。

この小実験の要点は、阿弥陀経二訳の問題を「意味的にどちらに近い」だけで解かないことである。意味埋め込みは、阿弥陀経二訳の同内容性をうまく捉える反面、訳語選択や引用経路の違いを薄める。親鸞文献のソース分析では、埋め込み近傍を探索の入口としつつ、経名・訳者名、固定句、注釈書の引文を別レイヤーとして重ねる必要がある。

5.5 訳者重心

訳者重心は、不空、玄奘、鳩摩羅什の 3 種を作成した。玄奘訳『称讃浄土佛攝取經』の近傍は、同じ玄奘訳の般若心経や解深密経ではなく、鳩摩羅什訳『阿弥陀経』および浄土系經典であった。今回の小規模コーパスでは、意味埋め込み上の近接は訳者よりも主題・内容に強く支配される傾向が見られた。ただし、訳者差の検出には、同一または近接主題の異訳ペアを増やしたうえで、文体特徴量と併用する必要がある。

表 7: 訳者重心の構成

訳者	テキスト数	対象
不空	2	金剛頂経、理趣経
玄奘	3	称讃浄土佛攝取經、般若心経、解深密経
鳩摩羅什	5	阿弥陀経、法華経、観音経、金剛経、維摩経

5.6 多言語比較パイロット

84000 英訳 *The Teaching Explaining the Thought* (Toh 106) を問い合わせテキストとし、漢訳テキスト群とのコサイン類似度を比較した。表 8 に上位近傍を示す。

表 8: 84000 英訳 Toh 106 から見た漢訳近傍

順位	近傍テキスト	コサイン類似度
1	解深密經 (T0676)	0.7662
2	維摩詰所説經 (T0475)	0.6926
3	金剛般若波羅蜜經 (T0235)	0.6922
4	般若波羅蜜多心經 (T0251)	0.6167
5	佛説阿彌陀經 (T0366)	0.5683

結果として、84000 英訳の最近傍は対応する漢訳『解深密經』となった。このことは、少なくとも Toh 106 と T0676 の組み合わせでは、英訳と漢訳という言語差を越えて対応經典が最近傍になったことを示す。ただし、維摩經や金剛經も 0.69 台で近く、大乘經典一般の主題的近さも反映されている。したがって、同一經典判定として評価するには、対応ペアと非対応ペアを増やし、top-1 accuracy、MRR、ROC-AUC などで検証する必要がある。

6 考察

阿彌陀經二訳の結果は、意味埋め込みが語彙差や訳語差を越えて、内容の近さを強く捉えることを示している。これは、同一または近接する原内容の漢訳を検出する用途には有用である可能性がある。一方で、文字単位 TF-IDF では阿彌陀經二訳の類似度が低く出た。これは、文体、訳語、語彙選択、固有名詞表記の差が文字 n-gram 特徴に強く反映されるためである。

チャンク分布を併用すると、平均点の近さをより細かく解釈できる。たとえば阿彌陀經二訳は本文平均ベクトルも近いが、チャンク近傍混合率も高く、文中の部分単位でも対応する意味領域が多いと考えられる。一方、平均点が比較的近くても、分布が細長い、または一部だけ重なる場合には、主題の一部共有と本文全体の近さを区別して読む必要がある。教行信証と浄土三部經の関係はこの例であり、三部經を根拠とする文献であるため本文平均では近いが、チャンク単位では引用・釈義・論述が混在するため、部分的な橋渡しと全体分布の差を分けて読む必要がある。

浄土系と真言系では、中心的な經典群が比較的まとまりやすい傾向が見えた。ただし、これは宗派そのものを分類したというより、宗派が重視するテキスト群の主題的近接を可視化した結果である。教行信証のような祖師文献は、多数の引用や教義的総合を含むため、単一經典とは異なる振る舞いを示す可能性がある。

禅系については、經典のみでは宗派的伝統差が分かれにくかった。これは失敗というより、投入データが宗派的伝統を表す層に届いていないことを示す結果である。禅宗の比較には、碧巖録、無門関、正法眼蔵、臨濟録、黄檗清規などの祖師文献・語録・規範文献を加える必要がある。

翻訳癖を扱うには、意味ベクトルとは別に、文字 n-gram、助字や虚詞の頻度、文長・句構造、固有訳語の対応関係、音写語と意識語の選択、同一サンスクリット語に対する漢訳語の揺れを特徴量として導入する必要がある。

以上を踏まえると、今後の分析単位は三層に分けるのがよい。第一に、内容・主題・教義的近接を捉える意味マップである。第二に、訳語、助字、句法、音写語、表記、文長などを捉える文体マップである。第三に、經名、訳者名、固定句、注釈引文、祖師文献引用を捉える引用・参照マップである。本稿の結果は、この三層のうち、

意味マップを先に構築し、その限界から文体マップと引用・参照マップの必要性を確認したものと位置づけられる。

親鸞文献における阿弥陀経二訳の参照分析も、同じ問題を示している。『入出二門偈』のように玄奘訳『称讃浄土経』を明示する資料では、経名・訳者名そのものが強い証拠となる。一方、『教行信証』のような総合的文献では、意味ベクトルは二訳の近接を反映するものの、引用経路や注釈伝統までは自動的に分解しない。したがって、今後の分析では、意味マップとは別に、引用・参照ソースマップを作り、経文本文、注釈引文、祖師文献引用を分けて扱うことが重要である。

多言語パイロットは、意味埋め込みが言語差を越えて同一経典性を拾う可能性を示した。ただし、今回用いたのはチベット語本文そのものではなく、84000 による英訳である。そのため、今後はチベット語本文、漢訳、英訳を同時に扱い、同一経典性、同一言語性、翻訳スタイルの影響を分離して評価する必要がある。

7 限界と今後の課題

本研究には、コーパスが小さいこと、大部経典の一部が全文比較ではないこと、宗派別参照群重心が単純平均であること、訳者重心のサンプル数が少ないこと、PCA による 2 次元配置が可視化用に過ぎないこと、文体ベクトルが未実装であること、といった限界がある。チャンク分布の楕円も 2 次元投影上の近似であり、厳密な分布重なり判定には高次元空間での近傍検索や分布間距離を併用する必要がある。多言語比較についても、現段階では英訳 1 本と漢訳対照群による最小実験であり、チベット語本文、章単位対応、複数経典ファミリーでの検証は未実施である。

今後は、SAT から各経典の全文を安定して取得し、各宗派について祖師文献、語録、儀礼文、注釈書を追加する。また、意味ベクトルとは別に文体ベクトルを作成し、翻訳者、時代、日本撰述漢文の特徴を可視化する。チャンク化については、固定長チャンクだけでなく、巻・品・段落などの自然単位によるチャンク化との比較を行う。宗派別参照群重心には重み付けを導入し、中心経典、勤行テキスト、祖師文献を区別する必要がある。多言語比較では、BDRC 等で確認できるチベット語本文を加え、必要に応じて仏教文献向け埋め込みモデルとの比較を行う。

親鸞の阿弥陀経理解を追う次段階では、『阿弥陀経集註』を重点資料とする。本文を単に一つのテキストとして埋め込むのではなく、経文本文、行間註、紙背・裏書、引用元と推定される注釈書を分けてデータ化する必要がある。そのうえで、羅什訳、玄奘訳、元照『阿弥陀経義疏』、善導系文献、法照系文献を参照源として並べることで、親鸞文献の「意味的近さ」と「引用・学習経路」の差をより精密に扱える可能性がある。

8 結論

本予備実験では、意味埋め込みを用いることで、阿弥陀経二訳のような同内容・近内容テキストの近接、および浄土系・真言系経典群の一定の主題的まとまりを確認できた。さらに、本文を平均点だけでなくチャンク分布として表示することで、各経典の内部的な広がりや部分的な重なりを観察できた。平均ベクトル類似度とチャンク近傍混合率を併用することで、本文全体の主題的近接と部分単位の分布重なりを区別して読めることも確認された。また、解深密経の多言語パイロットでは、84000 英訳の最近傍が対応する漢訳となった。一方で、訳者差や宗派的伝統差を精密に捉えるには、意味埋め込みだけでは不十分である。特に訳者の癖を分析するには、文字 n-gram、訳語対応、助字、句法などを用いた文体特徴量を別レイヤーとして導入する必要がある。

したがって、本研究の現段階の成果は、宗派分類器の完成ではなく、仏教文献群を探索するための意味地図の基盤を構築した点にある。今後、データを拡張し、意味マップ、文体マップ、引用・参照マップを分離して重ねることで、宗派、訳者、時代、日本撰述漢文の差異をより精密に検討できると考えられる。

参考文献

- [1] SAT 大正新脩大藏經テキストデータベース研究会。SAT 大正新脩大藏經テキストデータベース。
<https://21dzk.l.u-tokyo.ac.jp/SAT/>
- [2] 浄土真宗本願寺派総合研究所。『浄土真宗聖典』聖教データベース。<https://j-soken.jp/ask/10831>
- [3] 浄土真宗本願寺派総合研究所。『浄土真宗聖典』聖教データベース（必ずお読みください）。https://j-soken.jp/ask/ask_5/640
- [4] 真宗大谷派（東本願寺）。真宗聖典検索サイト『入出二門偈』。<https://shinshuseiten.higashihonganji.or.jp/contents.html?id=2&page=543>
- [5] 名古屋大学デジタルアーカイブ。観無量寿経集註附阿弥陀経集註。<https://da.adm.thers.ac.jp/item/n004-20230901-00882>
- [6] 千葉隆誓。親鸞『阿弥陀経集註』における元照『阿弥陀経義疏』引文について。2014。https://buddhism.lib.ntu.edu.tw/jp/search/search_detail.jsp?seq=546211
- [7] 浄土宗。新纂浄土宗大辞典「称讃浄土仏摂受経」。<https://jodoshuzensho.jp/daijiten/index.php/%E7%A7%B0%E8%AE%83%E6%B5%84%E5%9C%9F%E4%BB%8F%E6%91%82%E5%8F%97%E7%B5%8C>
- [8] 84000: Translating the Words of the Buddha. The Teaching Explaining the Thought, Toh 106.
<https://read.84000.co/translation/toh106.html>
- [9] 84000: Translating the Words of the Buddha. Terms of Use. <https://www.84000.co/documents/terms-of-use>
- [10] OpenAI. Embeddings. OpenAI Platform Documentation. <https://platform.openai.com/docs/guides/embeddings>
- [11] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.
- [12] I. T. Jolliffe. *Principal Component Analysis*. Springer, 2nd edition, 2002.
- [13] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT*, 2019.
- [14] John F. Burrows. “Delta”: a Measure of Stylistic Difference and a Guide to Likely Authorship. *Literary and Linguistic Computing*, 17(3):267–287, 2002. <https://doi.org/10.1093/llc/17.3.267>
- [15] Moshe Koppel, Jonathan Schler, and Shlomo Argamon. Computational Methods in Authorship Attribution. *Journal of the American Society for Information Science and Technology*, 60(1):9–26, 2009. <https://doi.org/10.1002/asi.20961>
- [16] Seishi Karashima. *A Glossary of Kumārajīva’s Translation of the Lotus Sutra*. The International Research Institute for Advanced Buddhology, Soka University, 2001. <https://glossaries.dila.edu.tw/glossaries/KKJ?locale=en>