

意味埋め込みを用いた仏教文献の宗派的配置・訳者差・多言語対応の予備的検討

未定

2026 年 6 月 1 日

要旨

本稿は、漢訳仏典および日本撰述仏教文献を対象に、意味埋め込みによって宗派別の参照テキスト群を可視化できるかを検討する予備的研究である。対象には、浄土系、法華系、真言系、禅系、華嚴系、法相系に関係する 15 テキストを用いた。各本文をチャンク化し、`text-embedding-3-large` によってチャンク埋め込みを作成し、本文単位のベクトルはチャンクベクトルの平均として得た。さらに、宗派重心と訳者重心を計算し、平均点の 2 次元配置、チャンク分布、類似度ヒートマップ、近傍テキストを確認した。加えて、漢訳『解深密経』とチベット大蔵経由来の 84000 英訳を用い、言語を越えて同一経典性が近傍関係として現れるかを小規模に検証した。

結果として、阿弥陀経とその玄奘訳別訳である『稱讃浄土佛攝受經』は、訳者が異なるにもかかわらず高い類似度を示した。一方で、玄奘訳の複数テキストは、訳者のみを理由に強くまとまるわけではなかった。チャンク分布では、本文平均点だけでは見えにくい各経典内部の広がりや重なりが確認でき、とくに阿弥陀経二訳はチャンク近傍混合率が高かった。これは、意味埋め込みが主として内容・主題の近さを捉え、訳語選択や文体上の癖は別の特徴量として扱う必要があることを示唆する。また、浄土三部経や真言系密教経典には一定のまとまりが見られたが、禅系については経典のみでは宗派差を十分に表現できなかった。多言語パイロットでは、84000 英訳 *The Teaching Explaining the Thought* の最近傍が漢訳『解深密経』となり、少なくともこの組み合わせでは意味埋め込みが言語差を越えて同一経典性を捉えうることが示された。

キーワード: 漢訳仏典、宗派比較、意味埋め込み、阿弥陀経、玄奘、鳩摩羅什、多言語比較、仏教文献情報学

1 はじめに

日本仏教の各宗派は、それぞれ特定の経典、祖師文献、儀礼的読誦テキストを重視してきた。たとえば浄土系では浄土三部経および祖師文献が重要であり、真言宗では大日経、金剛頂経、理趣経などの密教経典が中心的位置を占める。一方、禅宗では般若心経、金剛経、維摩経などが参照されるが、宗派の特徴は経典そのものよりも語録、清規、祖師文献に強く現れる可能性がある。

近年の大規模言語モデルおよび埋め込みモデルは、テキストの意味的近さを高次元ベクトルとして表現できる。本研究では、この手法を仏教文献に適用し、宗派ごとの参照テキスト群の配置を可視化できるかを検討する。あわせて、阿弥陀経の異訳や同一訳者の複数テキストを用い、意味的近さと翻訳文体の差がどのように現れるかを予備的に確認する。さらに、漢訳仏典とチベット大蔵経由来の英訳を対照し、意味埋め込みが言語を越えた同一経典性をどの程度拾えるかを試験的に確認する。

本稿の目的は、宗派分類の正解モデルを作ることではない。むしろ、各宗派が参照するテキスト群を意味空間上に置いたとき、どのような近接関係や解釈上の問題が現れるかを把握することである。

2 研究課題

本稿では、以下の三つの問いを設定する。

1. 意味埋め込みによって、浄土三部経や真言系密教経典のような主題的まとまりを確認できるか。

2. 宗派ごとの参照テキスト群を重心として可視化した場合、宗派の特徴をどの程度表現できるか。
3. 阿弥陀経の異訳および同一訳者の複数テキストを比較したとき、意味の近さと翻訳文体の差を区別できるか。
4. 漢訳仏典とチベット大蔵経由来の英訳を比較したとき、同一経典性は言語差を越えて近傍関係として現れるか。

3 データ

本文は主に SAT 大正新脩大蔵経テキストデータベースから取得した。『顯淨土眞實教行證文類』については、浄土真宗本願寺派総合研究所『浄土真宗聖典』聖教データベースの収載・利用規定を確認し、同データベースを利用した旨を明記する必要があるため、本稿の参考文献にも同データベースを掲げる。一部の検証用テキストには、全文ではない既存取得本文を用いた。v0.1 で用いたテキスト数は 15、チャンク数は 433 である。多言語パイロットでは、SAT 由来の漢訳『解深密経』と、84000 Reading Room で公開されている *The Teaching Explaining the Thought* (Toh 106) 英訳を用いた。84000 本文は研究用キャッシュとして扱い、本文そのものは本稿に転載しない。

表 1: 対象テキスト

系統	テキスト	ID	訳者・著者
浄土系	佛説無量壽經	T0360	康僧鎧
浄土系	佛説觀無量壽佛經	T0365	曇良耶舍
浄土系	佛説阿彌陀經	T0366	鳩摩羅什
浄土系	稱讃淨土佛攝受經	T0367	玄奘
浄土真宗	顯淨土眞實教行證文類	J-SOKEN 聖教 DB	親鸞
法華系	妙法蓮華經	T0262	鳩摩羅什
法華・禅系	觀世音菩薩普門品	T0262	鳩摩羅什
真言系	大毘盧遮那成佛神變加持經	T0848	善無畏・一行
真言系	金剛頂一切如來眞實攝大乘現證大教王經	T0865	不空
真言系	大樂金剛不空眞實三麼耶經	T0243	不空
禅・真言系	般若波羅蜜多心經	T0251	玄奘
法相系	解深密經	T0676	玄奘
禅系	金剛般若波羅蜜經	T0235	鳩摩羅什
禅系	維摩詰所說經	T0475	鳩摩羅什
華嚴系	大方廣佛華嚴經	T0279	實叉難陀

本実験は予備的なものであり、すべての大部経典を完全な全文として取得できているわけではない。特に法華経の既存取得本文は短く、全文ではない可能性が高い。また、SAT 本文の再配布ではなく、実験結果の要約と派生データの確認を目的とする。

4 方法

4.1 チャンク化と埋め込み

本文は既定で 700 トークン、100 トークンの重なりによりチャンク化した。各チャンクに対して `text-embedding-3-large` による埋め込みを作成した。同一モデル・同一本文のチャンクについてはキャッ

シュを利用し、再実行時に API を呼び直さないようにした。本文単位のベクトルは、当該本文に属するチャンクベクトルの平均として計算した。

4.2 類似度と重心

本文間の類似度はコサイン類似度によって計算した。宗派重心は、当該宗派に属する `core_sutra` および `founder_text` の本文ベクトルの平均として定義した。訳者重心は、同一訳者に属する複数テキストの本文ベクトルの平均として定義した。ただし、今回の訳者重心はサンプル数が少ないため、可視化上の補助線として扱う。

4.3 可視化と対照実験

本文ベクトル、宗派重心、訳者重心を同一空間に配置し、2次元表示には PCA を用いた。阿弥陀経二訳については、意味埋め込みに加えて文字単位 TF-IDF も計算した。文字単位 TF-IDF では 2 から 5 文字の n-gram を用いた。これは、意味的近さではなく、語彙選択や表記の差を捉えるための簡易的な対照実験である。

平均ベクトルだけでは、長い経典や複数主題を含む文献の内部的な広がりが見えなくなる。そこで、主要テキストについてはチャンク単位の埋め込みを PCA で 2次元表示し、各テキストのチャンク群に対して 1 標準偏差楕円を重ねた。また、2次元投影の重なりは歪みを含むため、元の高次元埋め込み空間で、あるテキストのチャンクの top-5 近傍に相手テキストのチャンクがどの程度入るかを「チャンク近傍混合率」として計算した。

4.4 多言語パイロット

多言語比較では、84000 Reading Room の *The Teaching Explaining the Thought* (Toh 106) を HTML から抽出し、SAT 由来の漢訳『解深密経』(T0676) と比較した。対照群として、金剛経、維摩経、般若心経、阿弥陀経の漢訳を加えた。評価は、84000 英訳の本文ベクトルから見た漢訳テキストの最近傍順位によって行った。

5 結果

5.1 宗派別お経マップ

図 1 に、本文ベクトルおよび訳者重心を PCA で 2次元表示した結果を示す。浄土系テキストは左上方向に比較的近く配置され、真言系密教経典は下方向にまとまる傾向が見られる。一方、禅系の経典のみからは、曹洞宗・臨済宗・黄檗宗の差は明確には出なかった。




図 1: 意味埋め込みによる宗派別お経マップ。丸は本文、菱形は訳者重心を表す。

5.2 チャンク分布と広がり

図 2 は、本文平均点ではなく、各本文を構成するチャンク群を点として表示したものである。楕円は各テキストの 1 標準偏差範囲を表す。平均点マップでは一点に集約されるテキストも、チャンク単位では主題の広がりや他テキストとの部分的重なりを持つことが分かる。特に、教行信証は引用や教義的総合を含むため、チャンク分布の広がり大きい。

チャンク PCA 第2軸

チャンク PCA 第1軸

無量寿経 阿弥陀経 教行信証 金剛頂経 解深密経 維摩経
 観無量寿経 稱讃淨土経 大日経 理趣経 金剛経 阿弥陀経 深密密経 教行信証

図 3 は、代表的な組み合わせを局所的に PCA 表示したものである。阿弥陀經二訳では、平均点だけでなくチャंक分布にも重なりが見られる。一方、真言系密教經典や般若・法相・禪系対照では、平均点の近さと分布の形が一致しない場合があり、本文全体を一点に潰すことの情報損失が確認できる。

高次元空間で計算したチャンク近傍混合率を図 4 に示す。値が大きいほど、相手テキストのチャンクが近傍に混ざりやすい。阿弥陀經二訳は 0.37 と高く、異訳間で分布が混ざる傾向が確認できる。対照的に、阿弥陀經と理趣經のような主題差の大きい組み合わせでは混合率が低い。




図 4: チャンク近傍混合率による分布重なり。各セルは、二つのテキストのチャンクを合わせたとき、各チャンクの top-5 近傍に相手テキストのチャンクが入る割合の平均を表す。

主要テキスト間の類似度を図 5 に示す。阿弥陀經、玄奘訳別記、無量壽經、觀無量壽經の近接が確認できる。また、大日經、金剛頂經、理趣經の間にも比較的高い類似度が見られる。




図 5: 主要テキスト間のコサイン類似度。値が大きいほど意味埋め込み上で近い。

5.3 阿弥陀経二訳

鳩摩羅什訳『佛説阿彌陀經』と玄奘訳『稱讃浄土佛攝受經』を比較したところ、意味埋め込みでは高い類似度を示した。一方、文字単位 TF-IDF では低い類似度となった（図 6）。




図 6: 阿弥陀経二訳の類似度比較。意味埋め込みは内容の近さを、文字単位 TF-IDF は語彙・表記差を強く反映する。

表 2: 阿弥陀経から見た近傍テキスト

近傍テキスト	コサイン類似度
稱讃浄土佛攝受經	0.8825
無量寿經	0.8694
觀無量寿經	0.8446
妙法蓮華經拔粹本文	0.8275
教行信証	0.8058

5.4 訳者重心

訳者重心は、不空、玄奘、鳩摩羅什の 3 種を作成した。玄奘訳『稱讃浄土佛攝受經』の近傍は、同じ玄奘訳の般若心経や解深密経ではなく、鳩摩羅什訳『阿弥陀経』および浄土系経典であった。これは、今回の意味埋め込みでは、訳者差よりも主題・内容の影響が強いことを示唆する。

表 3: 訳者重心の構成

訳者	テキスト数	対象
不空	2	金剛頂経、理趣経
玄奘	3	稱讃浄土佛攝受經、般若心経、解深密経
鳩摩羅什	5	阿弥陀経、法華経、觀音経、金剛経、維摩経

5.5 多言語比較パイロット

84000 英訳 *The Teaching Explaining the Thought* (Toh 106) を問い合わせテキストとし、漢訳テキスト群とのコサイン類似度を比較した。表 4 に上位近傍を示す。

表 4: 84000 英訳 Toh 106 から見た漢訳近傍

順位	近傍テキスト	コサイン類似度
1	解深密經 (T0676)	0.7662
2	維摩詰所説經 (T0475)	0.6926
3	金剛般若波羅蜜經 (T0235)	0.6922
4	般若波羅蜜多心經 (T0251)	0.6167
5	佛説阿彌陀經 (T0366)	0.5683

結果として、84000 英訳の最近傍は対応する漢訳『解深密經』となった。このことは、少なくとも本組み合わせでは、意味埋め込みが英訳と漢訳という言語差を越えて同一經典性を拾っている可能性を示す。ただし、維摩經や金剛經も 0.69 台で近く、大乘經典一般の主題的近さも反映されているため、同一經典判定として用いるには、異言語ペアをさらに増やし、同一作品内類似度と別作品類似度の差を検証する必要がある。

6 考察

阿弥陀經二訳の結果は、意味埋め込みが語彙差や訳語差を越えて、内容の近さを強く捉えることを示している。これは、同一または近接する原内容の漢訳を検出する用途には有用である可能性がある。一方で、文字単位 TF-IDF では阿弥陀經二訳の類似度が低く出た。これは、文体、訳語、語彙選択、固有名詞表記の差が文字 n-gram 特徴に強く反映されるためである。

チャンク分布を併用すると、平均点の近さをより細かく解釈できる。たとえば阿弥陀經二訳は本文平均ベクトルも近いが、チャンク近傍混合率も高く、文中の部分単位でも対応する意味領域が多いと考えられる。一方、平均点が比較的近くても、分布が細長い、または一部だけ重なる場合には、主題の一部共有と本文全体の近さを区別して読む必要がある。

浄土系と真言系では、中心的な經典群が比較的まとまりやすい傾向が見えた。ただし、これは宗派そのものを分類したというより、宗派が重視するテキスト群の主題的近接を可視化した結果である。教行信証のような祖師文献は、多数の引用や教義的総合を含むため、単一經典とは異なる振る舞いを示す可能性がある。

禪系については、經典のみでは宗派差が分かれにくかった。これは失敗というより、投入データが宗派差を表す層に届いていないことを示す結果である。禪宗の比較には、碧巖録、無門関、正法眼蔵、臨濟録、黄檗清規などの祖師文献・語録・規範文献を加える必要がある。

翻訳癖を扱うには、意味ベクトルとは別に、文字 n-gram、助字や虚詞の頻度、文長・句構造、固有訳語の対応関係、音写語と意識語の選択、同一サンスクリット語に対する漢訳語の揺れを特徴量として導入する必要がある。

多言語パイロットは、意味埋め込みが言語差を越えて同一經典性を拾う可能性を示した。ただし、今回用いたのはチベット語本文そのものではなく、84000 による英訳である。そのため、今後はチベット語本文、漢訳、英訳を同時に扱い、同一經典性、同一言語性、翻訳スタイルの影響を分離して評価する必要がある。

7 限界と今後の課題

本研究には、コーパスが小さいこと、大部經典の一部が全文比較ではないこと、宗派重心が単純平均であること、訳者重心のサンプル数が少ないこと、PCA による 2 次元配置が可視化用に過ぎないこと、文体ベクトルが未実装であること、といった限界がある。チャンク分布の楕円も 2 次元投影上の近似であり、厳密な分布重なるの判定には高次元空間での近傍検索や分布間距離を併用する必要がある。多言語比較についても、現段階では英訳 1 本と漢訳対照群による最小実験であり、チベット語本文、章単位対応、複数經典ファミリーでの検証は未実

施である。

今後は、SAT から各経典の全文を安定して取得し、各宗派について祖師文献、語録、儀礼文、注釈書を追加する。また、意味ベクトルとは別に文体ベクトルを作成し、翻訳者、時代、日本撰述漢文の特徴を可視化する。宗派重心には重み付けを導入し、中心経典、勤行テキスト、祖師文献を区別する必要がある。多言語比較では、BDRC 等で確認できるチベット語本文を加え、必要に応じて仏教文献向け埋め込みモデルとの比較を行う。

8 結論

本予備実験では、意味埋め込みを用いることで、阿弥陀経二訳のような同内容・近内容テキストの近接、および浄土系・真言系経典群の一定のまとまりを確認できた。さらに、本文を平均点だけでなくチャンク分布として表示することで、各経典の内部的な広がりや部分的な重なりを観察できた。また、解深密経の多言語パイロットでは、84000 英訳の最近傍が対応する漢訳となり、意味埋め込みが言語差を越えた同一経典性を捉えうることが示唆された。一方で、訳者差や宗派差を精密に捉えるには、意味埋め込みだけでは不十分である。特に訳者の癖を分析するには、文字 n-gram、訳語対応、助字、句法などを用いた文体特徴量を別レイヤーとして導入する必要がある。

したがって、本研究の現段階の成果は、宗派分類器の完成ではなく、仏教文献群を探索するための意味地図の基盤を構築した点にある。今後、データを拡張し、意味マップと文体マップを重ねることで、宗派、訳者、時代、日本撰述漢文の差異をより精密に検討できると考えられる。

参考文献

- [1] SAT 大正新脩大藏經テキストデータベース研究会。SAT 大正新脩大藏經テキストデータベース。 <https://21dzk.1.u-tokyo.ac.jp/SAT/>
- [2] 浄土真宗本願寺派総合研究所。『浄土真宗聖典』聖教データベース。 <https://j-soken.jp/ask/10831>
- [3] 浄土真宗本願寺派総合研究所。『浄土真宗聖典』聖教データベース（必ずお読みください）。 https://j-soken.jp/ask/ask_5/640
- [4] 84000: Translating the Words of the Buddha. The Teaching Explaining the Thought, Toh 106. <https://read.84000.co/translation/toh106.html>
- [5] 84000: Translating the Words of the Buddha. Terms of Use. <https://www.84000.co/documents/terms-of-use>
- [6] OpenAI. Embeddings. OpenAI Platform Documentation. <https://platform.openai.com/docs/guides/embeddings>
- [7] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.
- [8] I. T. Jolliffe. *Principal Component Analysis*. Springer, 2nd edition, 2002.
- [9] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT*, 2019.